

Evaluación Cuantitativa — Essentia KNN vs CLAP

Voice2Sample · TFG, Ingeniería Informática

Metodología de evaluación para Information Retrieval Musical

Índice

1. [Introducción y Objetivo](#)
2. [Metodología de Pruebas](#)
3. [Diccionario de Métricas](#)
4. [Sistema de Puntuación Avanzado](#)
5. [Interpretación de Resultados](#)
6. [Uso del Script](#)
7. [Referencias](#)

1. Introducción y Objetivo de la Evaluación

La recuperación de información musical (*Music Information Retrieval*, MIR) plantea un reto fundamental: definir de forma computacionalmente tratable qué significa que dos audios sean *similares*. Este concepto es inherentemente multidimensional, ya que dos productores musicales pueden coincidir o discrepar según si priorizan el ritmo, el timbre, la tonalidad o la textura perceptual general.

El sistema **Voice2Sample** implementa dos estrategias de recuperación que representan filosofías radicalmente distintas:

- **CLAP** (*Contrastive Language-Audio Pretraining*) es un modelo de **búsqueda semántica latente**. A partir del modelo `laion/clap-htsat-unfused`, cada audio queda representado como un vector denso de 512 dimensiones en un espacio de embeddings aprendido mediante aprendizaje contrastivo sobre millones de pares audio-texto. La similitud entre dos audios se mide como la **similitud coseno** entre sus vectores de embedding, capturando relaciones perceptuales de alto nivel como el mood, el género o la textura tímbrica global.
- **Essentia KNN** es un modelo de **búsqueda acústica paramétrica**. Cada audio se describe mediante **126 descriptores acústicos** extraídos con la biblioteca Essentia (ritmo, melodía, timbre, tonalidad,

dinámica). La búsqueda se realiza mediante un índice KNN con **distancia euclídea** en el espacio estandarizado. La similitud bruta se define como $s = 1/(1 + d_{\text{eucl}})$.

Preguntas de investigación

- 1. ¿Cuál de los dos modelos produce resultados *globalmente más similares* al audio de consulta, en una escala comparable?
- 2. ¿Cuál es más preciso en la recuperación de audios con el mismo **tempo** (*BPM Agreement*)?
- 3. ¿En qué medida los dos modelos son **complementarios** (atacan el problema desde dimensiones ortogonales)?

2. Metodología de Pruebas (*Experimental Setup*)

2.1 Corpus de Evaluación

Ambos modelos operan sobre el **mismo corpus local** de audios preprocesados: una colección de muestras en formato WAV que constituye la base de datos de Voice2Sample. El corpus está formado por $N = 2\,502$ audios con sus correspondientes metadatos (BPM, etiquetas, etc.).

Para evitar **contaminación del test** (*data leakage*), los audios de consulta (*queries*) se seleccionan del propio corpus, lo que permite disponer de los descriptores del query ya precalculados y evaluar la capacidad de cada modelo para recuperar los vecinos más próximos de un ítem conocido.

2.2 Entorno de Pruebas

El entorno está diseñado para ser **reproducibile, eficiente y libre de reprocesamiento** en tiempo real.

Componente	Archivo	Descripción
Descriptores Essentia	music_all.json	{audio_id: {feature_key: float}} — 1 126 descriptores por audio, calculados offline por el pipeline de Essentia.
Modelos Essentia KNN	knn_essentia.joblib meta_essentia.joblib columnas_essentia.joblib	Bundle serializado con <code>scikit-learn</code> : <code>StandardScaler</code> ajustado + <code>NearestNeighbors</code> entrenado + metadatos.
Embeddings CLAP	embeddings_output.json	{"items": [{"path": str, "embedding": [float × 512]}]} — embeddings precalculados del corpus. Los vectores se L2-normalizan al cargarse para que el producto escalar equivalga a la similitud coseno.

El script acepta `--me-json` y `--clap-json` como parámetros independientes para evitar colisiones entre formatos, y `--models-dir` para localizar los ficheros `.joblib`.

2.3 Protocolo de Evaluación Top-K y Doble Pasada

Dado un conjunto de queries $Q = \{q_1, \dots, q_m\}$ y un parámetro K (habitualmente $K = 5$), para cada modelo se recuperan los K audios más similares al query (excluyendo el propio query) y se evalúan las métricas de la Sección 3.

Para garantizar que la normalización sea **global y estable**, el script realiza dos pasadas:

1. **Primera pasada** — calcula las similitudes brutas de cada query frente a *todos* los N audios del dataset. Esto proporciona la distribución empírica completa de similitudes de cada modelo.
2. **Segunda pasada** — normaliza los scores top-K usando los límites globales obtenidos en la primera pasada y computa las métricas finales.

3. Diccionario de Métricas (*Core Metrics*)

3.1 Similitud Coseno Media

Definición. La similitud coseno entre dos vectores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$ mide el coseno del ángulo que forman:

$$\text{cos_sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \cdot \|\mathbf{v}\|}$$

Para vectores L2-normalizados ($\|\mathbf{u}\| = \|\mathbf{v}\| = 1$), se reduce al producto escalar: $\text{cos_sim}(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{v}$.

Cálculo. La similitud media de los K resultados para el query q en el modelo CLAP:

$$\bar{s}_{\text{CLAP}}(q) = \frac{1}{K} \sum_{k=1}^K \text{cos_sim}(\mathbf{e}_q, \mathbf{e}_{r_k})$$

Para Essentia KNN, la similitud bruta a partir de la distancia euclídea en espacio estandarizado:

$$s_{\text{Ess}}(q, r) = \frac{1}{1 + d_{\text{eucl}}(q, r)} \quad \Rightarrow \quad s \in (0, 1]$$

Interpretación.

Valor	Significado
$\bar{s} \rightarrow 1$	Los K resultados son muy próximos al query en el espacio del modelo. Alta coherencia interna.

Valor	Significado
$\bar{s} \rightarrow 0$	Resultados alejados del query. Baja calidad de recuperación.

⚠ **Advertencia crítica:** los rangos naturales de ambos modelos son distintos. CLAP produce valores típicamente en $[0.5, 0.99]$; Essentia en $[0.05, 0.5]$. **Un 0.4 en CLAP no equivale a un 0.4 en Essentia.** Por ello se aplica la Normalización Global descrita en §4.1 antes de cualquier comparación directa.

3.2 BPM Agreement (Tolerancia ± 10 BPM)

Definición. Proporción de los K resultados cuyo tempo se encuentra dentro de la tolerancia τ respecto al BPM del query:

$$\text{BPM_agr}(q) = \frac{|\{r \in \text{Top-}K : |bpm_r - bpm_q| \leq \tau\}|}{K} \times 100\%$$

con $\tau = 10$ BPM por defecto.

Por qué $\tau = 10$ BPM. En producción musical electrónica, muestras con una diferencia de tempo inferior a 10 BPM son generalmente compatibles sin *time-stretching* perceptible, o pueden sincronizarse con ajustes menores. Esta tolerancia es un estándar práctico en herramientas de gestión de samples y DJing profesional (Rekordbox, Serato).

Relevancia en MIR. El tempo es una de las dimensiones más críticas en la búsqueda de samples: un productor que trabaja a 140 BPM necesita muestras rítmicamente compatibles. Un modelo que devuelva audios perceptualmente similares pero a 90 BPM será **inutilizable** en contexto de producción, independientemente de su similitud tímbrica. El BPM Agreement actúa como una **métrica de utilidad práctica** más allá de la coherencia representacional interna.

Los valores de BPM se extraen del campo `rhythm.bpm` en `music_all.json`, calculado por el extractor de Essentia durante el procesamiento del corpus.

3.3 Top-K Overlap (Solapamiento entre modelos)

Definición. Porcentaje de resultados coincidentes entre ambos modelos para el mismo query:

$$\text{Overlap}(q) = \frac{|\text{Top-}K_{\text{Ess}}(q) \cap \text{Top-}K_{\text{CLAP}}(q)|}{\max(K_{\text{Ess}}, K_{\text{CLAP}})} \times 100\%$$

Interpretación.

Overlap	Significado
> 60 %	Alta coincidencia. Ambos modelos consideran similares a los mismos audios. Hay coherencia entre representaciones, pero también redundancia: combinarlos aportaría poca diversidad.
< 30 %	 Resultado deseable. Los modelos atacan el problema desde dimensiones ortogonales . Essentia captura características acústicas objetivas (ritmo, espectro, tonalidad); CLAP captura similitud semántica y perceptual de alto nivel. Un sistema híbrido que fusione ambos rankings (p. ej., mediante <i>Reciprocal Rank Fusion</i>) ampliaría la diversidad de recomendaciones sin sacrificar relevancia.

4. Sistema de Puntuación Avanzado (*Ranking Score*)

4.1 Normalización Global Min-Max

El problema. Las similitudes brutas de CLAP y Essentia habitan escalas distintas: cualquier comparación directa de sus valores numéricos carecería de rigor estadístico. Incluso dentro del mismo modelo, las distribuciones varían entre queries.

La solución. Se aplica normalización Min-Max **global**, usando los límites calculados sobre la distribución empírica completa del modelo — todas las similitudes, de todas las queries, frente a todos los audios del corpus (excepto el propio query):

$$\tilde{s}(i) = \frac{s(i) - s_{\min}^{\text{global}}}{s_{\max}^{\text{global}} - s_{\min}^{\text{global}}} \times 100$$

donde los límites se calculan sobre el conjunto:

$$\mathcal{S} = \bigcup_{q \in Q} \{s(q, r) : r \in \mathcal{D} \setminus \{q\}\}$$

siendo $\mathcal{D}$ el corpus completo y Q el conjunto de queries de evaluación.

Resultado. Tras la normalización, $\tilde{s} \in [0, 100]$ para ambos modelos con el mismo significado semántico: «este resultado ocupa el X% superior de la distribución de similitud del modelo sobre el dataset». Un $\tilde{s} = 85$ en CLAP y un $\tilde{s} = 85$ en Essentia son ahora directamente comparables.

4.2 Penalización por Posición (*Discounted Cumulative Gain*)

Motivación. Una vez normalizadas las similitudes, la **posición** de un resultado en el ranking sigue siendo información relevante. Un modelo que coloca el audio más similar en la posición 1 debe ser premiado frente a otro que lo coloca en la posición 5, aunque ambos devuelvan el mismo conjunto de audios.

Fórmula. Se adopta la función de descuento del *Normalized Discounted Cumulative Gain* (NDCG), propuesta por Järvelin & Kekäläinen (2002):

$$w(\text{rank}) = \frac{1}{\log_2(\text{rank} + 1)}$$

Rank k	$\log_2(k + 1)$	$w(k)$
1	1.000	1.0000
2	1.585	0.6309
3	2.000	0.5000
4	2.322	0.4307
5	2.585	0.3869

Esta función es **decreciente y convexa**: la diferencia de peso entre los puestos 1 y 2 es mayor que entre el 4 y el 5, reflejando el comportamiento real del usuario que explora preferentemente los primeros resultados.

4.3 *Weighted Score* (Puntuación Final)

Definición. El *Weighted Score* combina la similitud normalizada de cada resultado con su peso posicional, normalizado por la suma de pesos para que el resultado siga en $[0, 100]$:

$$\text{WS}(q) = \frac{\sum_{k=1}^K \tilde{s}(k) \cdot w(k)}{\sum_{k=1}^K w(k)}$$

Propiedades.

- $\text{WS}(q) \in [0, 100]$ para ambos modelos, en la misma escala.
- Si todos los resultados tienen similitud máxima: $\text{WS}(q) = 100$.
- El score **penaliza doblemente**: por similitud baja y por posición alta. Un modelo que coloca resultados mediocres en los primeros puestos obtiene un WS significativamente menor que uno que coloca

resultados excelentes en los primeros puestos.

Score global. El *Weighted Score* medio sobre el conjunto de queries Q es la métrica principal de comparación:

$$\overline{WS} = \frac{1}{|Q|} \sum_{q \in Q} WS(q)$$

El modelo con mayor $\overline{WS}$ se declara **ganador en búsqueda por similitud general**.

5. Interpretación de Resultados y Casos de Uso

5.1 Guía de Interpretación de Escenarios

Escenario	WS	BPM Agr.	Interpretación
A	CLAP > Essentia	Essentia > CLAP	Resultado más frecuente. Cada modelo gana en su dimensión natural. Sistema híbrido óptimo.
B	CLAP > Essentia	CLAP > Essentia	CLAP ha capturado el tempo implícitamente. Corpus estilísticamente homogéneo.
C	Essentia > CLAP	Essentia > CLAP	Los descriptores DSP son más discriminativos que los embeddings para este corpus.
D	≈ empate	≈ empate	Overlap alto: los modelos convergen. Corpus con poca variedad o queries muy genéricas.

Escenario A en detalle — CLAP gana en WS, Essentia gana en BPM Agreement:

Significa que CLAP recupera audios perceptualmente más próximos al query (similitud semántica global), pero sin garantizar compatibilidad de tempo. Essentia recupera audios con tempo compatible con alta fiabilidad, gracias a los descriptores rítmicos explícitos (`rhythm.bpm` , `rhythm.onset_rate` , `rhythm.danceability`), aunque su similitud global puede ser más dispersa en el espacio de 1 126 dimensiones.

Implicación práctica: ningún modelo es superior en términos absolutos; cada uno es óptimo para un subconjunto de casos de uso. La fusión de rankings (*ensemble*) produce resultados superiores a cualquiera de los dos por separado.

5.2 La Brecha Semántica vs. Precisión Acústica

Los resultados de esta evaluación deben interpretarse a la luz de la **brecha semántica** (*semantic gap*): la distancia entre la representación computacional de un audio y la percepción subjetiva humana del mismo. Ambos modelos abordan esta brecha desde extremos opuestos.

Casos de uso donde CLAP es el modelo óptimo

El usuario describe o ejemplifica un estilo, textura o mood.

- **Búsqueda por analogía tímbrica** — el usuario sube un pad ambiental oscuro y busca samples con la misma atmósfera, independientemente del BPM exacto. CLAP captura la "oscuridad" y el carácter ambiental como atributos latentes; Essentia solo puede comparar coeficientes espectrales.
- **Búsqueda cross-genre** — el usuario busca *"algo que suene como este bassline de funk pero en contexto electrónico"*. La similitud semántica de CLAP puede cruzar fronteras de género que los descriptores DSP no atraviesan.
- **Exploración creativa** — cuando el usuario no sabe exactamente qué busca. Los resultados de CLAP tienden a ser creativamente estimulantes, ya que el espacio de embeddings organiza los audios por relaciones semánticas aprendidas de datos humanos.

Casos de uso donde Essentia KNN es el modelo óptimo

El usuario necesita compatibilidad técnica precisa con un proyecto en curso.

- **Sincronización de tempo** — el usuario trabaja a 140 BPM y necesita samples rítmicamente compatibles. El BPM Agreement superior de Essentia garantiza resultados utilizables sin *time-stretching*.
- **Matching de características acústicas** — el usuario busca un sample con el mismo rango de frecuencias y nivel de energía que otro ya en uso (para *layering*). Los descriptores de bajo nivel de Essentia son más precisos en estas dimensiones técnicas.
- **Géneros rítmicamente estrictos** — *drum and bass*, *techno* o música clásica, donde la precisión de BPM y la coherencia espectral son no-negociables.

Síntesis: argumento para un sistema híbrido

La existencia de estos dos perfiles complementarios es la motivación técnica principal para el diseño híbrido de Voice2Sample. Si se define la función de utilidad $U(q, r)$ de un resultado r para un query q como:

$$U(q, r) = \alpha \cdot \text{WS}_{\text{CLAP}}(q, r) + (1 - \alpha) \cdot \text{WS}_{\text{Ess}}(q, r)$$

donde $\alpha \in [0, 1]$ controla el balance entre búsqueda semántica y acústica, el sistema puede configurarse dinámicamente según el contexto del usuario. La evaluación cuantitativa presentada en este documento proporciona los fundamentos empíricos para justificar este diseño y calibrar el parámetro α de forma informada.

6. Uso del Script

```
# Instalación de dependencias
pip install numpy scikit-learn joblib rich

# Ejecución básica (5 queries automáticos)
python Evaluation/evaluacion_cuantitativa.py \
    --me-json      audio_processing/Processing/descriptors/music_all.json \
    --models-dir   audio_processing/Processing/models \
    --clap-json    Dataset/embeddings_output.json \
    --top-k        5

# Ejecución con queries específicos y exportación JSON
python Evaluation/evaluacion_cuantitativa.py \
    --me-json      audio_processing/Processing/descriptors/music_all.json \
    --models-dir   audio_processing/Processing/models \
    --clap-json    Dataset/embeddings_output.json \
    --top-k        5 \
    --query-ids    100270 101894 101895 \
    --output-json  Evaluation/resultados.json
```

Parámetro	Obligatorio	Descripción
--me-json	✓	JSON de descriptores Essentia (music_all.json)
--models-dir	✓	Directorio con los ficheros .joblib de Essentia KNN
--clap-json	✓	JSON de embeddings CLAP (embeddings_output.json)
--top-k	✗	Número de resultados por query (default: 5)
--query-ids	✗	IDs de audio a evaluar. Si se omite, los 5 primeros comunes
--output-json	✗	Ruta para guardar resultados en JSON

7. Referencias

- Järvelin, K., & Kekäläinen, J. (2002). *Cumulative gain-based evaluation of IR techniques*. ACM Transactions on Information Systems, 20(4), 422–446.
- Laion-AI. (2022). *CLAP: Learning Audio Concepts From Natural Language Supervision*. arXiv:2206.04769.

- Bogdanov, D., et al. (2013). *Essentia: an Audio Analysis Library for Music Information Retrieval*. ISMIR 2013.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. Cap. 8: Evaluation in information retrieval.

Documento generado como parte de la memoria del TFG «Voice2Sample» — Evaluación Cuantitativa de Sistemas de Recuperación de Audio por Similitud.